

機器學習十大必學演算法

精選核心演算法深度解析・從原理、應用到初學者學習藍圖

一、導論與核心思維導圖

在當今大數據與人工智慧驅動的時代，機器學習已成為解決複雜問題、預測未來趨勢與自動化決策的核心技術。然而，面對眾多的數學模型與演算法，初學者往往容易迷失在複雜的公式與代碼中。本講義嚴謹對照精選的「十大機器學習演算法資訊圖表」，由淺入深地將這些演算法分為三大主軸：**數值預測（Regression）**、**標籤分類（Classification）**與**資料分群及降維（Clustering & Dimensionality Reduction）**。

理解這些演算法的核心要領在於建立「簡易記憶線（Simple Memory Line）」：從最基礎的**預測數值（線性迴歸）**，進階到**分類標籤（邏輯迴歸、決策樹等）**，再到無監督的**資料聚類（K-Means）**與**特徵篩選減量（PCA）**，最終邁向能夠**學習深層模式**的深度神經網路。

二、十大演算法綜合總覽表

排名	演算法名稱	學習類型	主要用途	核心運作機制
1	線性迴歸 (Linear Regression)	監督式學習	預測連續性數值	尋找最佳擬合直線，最小化預測值與實際值的殘差平方和。
2	邏輯迴歸 (Logistic Regression)	監督式學習	二元分類	利用 Sigmoid 函數將線性輸出映射至 0 到 1 之間，預測機率。
3	決策樹 (Decision Tree)	監督式學習	分類與迴歸	依據特徵資訊增益將資料像樹狀分支般切割，進行層層決策。
4	隨機森林 (Random Forest)	監督式學習	強力通用預測 (分類/迴歸)	結合多棵決策樹的投票或平均結果，提升準確度並防止過擬合。
5	支持向量機 (SVM)	監督式學習	具備清晰邊界的分類	在高維空間中尋找一個最佳超平面，使不同類別間的邊界最大化。
6	K-最近鄰演算法 (KNN)	監督式學習	簡單分類與迴歸	根據新資料點在空間中距離最近的 K 個鄰居的類別進行多數決。
7	單純貝氏 (Naive Bayes)	監督式學習	文本分類、垃圾郵件偵測	基於貝氏定理，並假設所有特徵在彼此之間皆完全獨立。
8	K-平均分群 (K-Means)	無監督式學習	相似資料的分組聚集	反覆計算資料點與 K 個群集中心的距離，最小化群內變異數。
9	主成分分析 (PCA)	無監督式學習	資料特徵降維	將高維度資料投影到新正交軸上，在保留最大變異數下減少特徵數。
10	神經網路與深度學習	監督 / 無監督	影像、語言與複雜模式識別	利用多層相互連接的節點（神經元）自動學習特徵並解決複雜問題。

三、各演算法深度技術解析

Rank 1: 線性迴歸 (Linear Regression)

監督式學習 主要用途：預測連續型數值（如房價、營收、溫度）

核心運作原理：

線性迴歸是機器學習中最基礎且歷史最悠久的統計模型。其目標是尋找一條最佳的直線（在多維空間中稱為超平面），用來描述自變數 X 與應變數 Y 之間的線性關係。數學核心在於最小化所有實際觀測點與預測直線之間的距離平方和，此方法稱為**最小平方方法 (Ordinary Least Squares, OLS)**。

其基本數學公式表示為：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

其中 β_0 是截距， β_i 是各特徵的權重係數，而 ε 為誤差項。模型透過梯度下降法 (Gradient Descent) 或正規方程 (Normal Equation) 來疊代更新權重，直到找到最能代表資料趨勢的直線。

Rank 2: 邏輯迴歸 (Logistic Regression)

監督式學習 主要用途：二元分類問題（如是否流失、是否患病、貸款是否違約）

核心運作原理：

雖然名稱帶有「迴歸」二字，但邏輯迴歸實質上是一個廣義線性**分類模型**。它之所以存在，是因為傳統線性迴歸的輸出範圍是正負無窮大，無法直接表示「機率」。邏輯迴歸在線性組合的基礎上，套用了一個非線性的 **Sigmoid 函數**（又稱邏輯函數），將任何實數輸入壓縮到 $(0, 1)$ 的區間內。

Sigmoid 函數的形式為：

$$S(z) = 1 / (1 + e^{-z})$$

當線性預測值 $z = \beta X$ 越高， $S(z)$ 越接近 1；反之則越接近 0。我們通常設定一個閾值（例如 0.5），當輸出機率大於 0.5 時，將樣本分類為 1，否則分類為 0。模型在訓練時使用對數損失函數 (Log Loss / Cross-Entropy Loss) 來優化參數。

Rank 3: 決策樹 (Decision Tree)

監督式學習

主要用途：分類與迴歸任務，適合具有可解釋性要求的場景

核心運作原理：

決策樹模擬了人類在做決策時的樹狀思考流程。它從根節點 (Root Node) 開始，根據資料特徵的某個切分點，將資料分流至不同的子分支，直到抵達葉節點 (Leaf Node) 並得到最終的預測結果。

如何選擇最佳的切分特徵是決策樹的核心。常見的演算法（如 ID3, C4.5, CART）會利用**資訊增益 (Information Gain)**、**資訊增益比 (Gain Ratio)** 或 **吉尼係數 (Gini Impurity)** 來評估。目標是讓每次切割後，子節點內部的資料純度越高越好（即混亂度、熵越低）。決策樹具備直觀、易解釋的優點，但缺點是若樹長得太深，極易產生過擬合 (Overfitting)。

Rank 4: 隨機森林 (Random Forest)

監督式學習

主要用途：強力且通用的預測（高度非線性資料的分類與迴歸）

核心運作原理：

隨機森林是為了解決單一決策樹容易過擬合的問題而誕生的**集成學習 (Ensemble Learning)** 演算法。它的核心哲學是「三個臭皮匠，勝過一個諸葛亮」。隨機森林透過**自助抽樣法 (Bootstrapping)** 從原始資料集中有放回地隨機抽取多個子樣本集，並在訓練每棵樹時，也隨機選取部分特徵（特徵隨機性）。

在這個機制下，演算法建立起數百棵獨立且各具特異性的決策樹。當有新資料需要預測時：

- 在**分類任務**中，讓所有決策樹進行投票，得票數最多的類別即為最終結果。
- 在**迴歸任務**中，將所有決策樹的輸出值取平均數作為最終預測。

這種雙重隨機性顯著降低了模型的方差 (Variance)，使其成為工程實務中極其穩定且強大的演算法。

Rank 5: 支持向量機 (Support Vector Machine, SVM)

監督式學習 **主要用途：** 具有清晰邊界的高維度分類、文字分類、生醫訊號分類

核心運作原理：

支持向量機的基本思想是在特徵空間中尋找一個**最佳超平面 (Optimal Hyperplane)**，將不同類別的資料點完美分開。所謂的「最佳」，是指該超平面距離兩側最近的資料點（這些關鍵點被稱為**支持向量 Support Vectors**）的距離達到最大化，這個距離稱為**邊界 (Margin)**。邊界越大，模型的泛化能力就越強。

當面對現實中無法用直線線性分類的複雜資料時，SVM 引入了**核函數 (Kernel Trick)** 機制（如 RBF 徑向基底核、多項式核）。核函數能將原本在低維空間線性不可分的資料，隱式地投影到更高維度的空間中，使其變得線性可分，這賦予了 SVM 極強的高維非線性建模能力。

Rank 6: K-最近鄰演算法 (K-Nearest Neighbors, KNN)

監督式學習 **主要用途：** 簡單直觀的分類與迴歸、推薦系統基礎

核心運作原理：

KNN 是一種基於實例的「惰性學習 (Lazy Learning)」演算法，它在訓練階段基本上不進行任何數學模型的擬合，只是單純地把訓練資料儲存起來。它的核心概念非常生活化：「物以類聚，人以群分」。

當輸入一個未知標籤的新資料點時，KNN 會計算該點與訓練集中所有點的幾何距離（如歐氏距離 Euclidean Distance 或曼哈頓距離）。接著找出距離最近的 **K** 個鄰居：

- 若執行**分類**，則觀察這 **K** 個鄰居中哪個類別最多，新資料就歸屬於該類別。
- 若執行**迴歸**，則直接取這 **K** 個鄰居數值的平均值。

K 值的選擇至關重要：**K** 太小模型會對雜訊極其敏感（過擬合）；**K** 太大則會導致邊界模糊（欠擬合）。

Rank 7: 單純貝氏 (Naive Bayes)

監督式學習 主要用途：文字分類、垃圾郵件過濾、情感分析

核心運作原理：

單純貝氏是基於機率論中**貝氏定理 (Bayes' Theorem)** 的經典分類器。其數學公式為：

$$P(C|X) = [P(X|C) \cdot P(C)] / P(X)$$

它被冠以「單純 (Naive)」之名，是因為它做了一個極度簡化的假設：**假設所有輸入特徵在給定輸出類別的條件下，彼此之間是完全獨立、互不影響的**。例如在垃圾郵件偵測中，模型假設「免費」和「點擊」這兩個詞在郵件中出現的機率是各自獨立的。

儘管在現實生活中這個假設幾乎不可能成立，但單純貝氏在實際應用中（尤其是高維度的文本資料）卻展現出驚人的高效率與不俗的準確度，且運算速度極快，非常適合即時處理大規模數據。

Rank 8: K-平均分群 (K-Means Clustering)

無監督式學習 主要用途：客戶分群、市場細分、圖像量化壓縮

核心運作原理：

與前七種需要歷史標籤（答案）的監督式學習不同，K-Means 處理的是沒有標籤的原始資料。它的任務是自動將本質相似的資料歸為一類，將資料點劃分為 **K** 個不同的群集 (Clusters)。

其運作流程採取不斷反覆的 EM 疊代演算法：

1. 隨機初始化選定 **K** 個點作為初始的群集中心 (Centroids)。
2. **指派步驟 (Assignment)**：計算每個資料點到這 **K** 個中心的距離，並將資料點指派給距離最近的那個中心。
3. **更新步驟 (Update)**：重新計算每個群集內所有點的幾何平均數，並將該平均位置設為新的群集中心。
4. 重複步驟 2 與 3，直到群集中心的位置不再發生顯著變動（收斂）為止。

K-Means 的缺點是必須事先人為指定 **K** 值（通常搭配手肘法 Elbow Method 決定），且對極端異常值較為敏感。

Rank 9: 主成分分析 (Principal Component Analysis, PCA)

無監督式學習 主要用途：資料特徵降維、資料視覺化、消除特徵間的多元共線性

核心運作原理：

在面對擁有成百上千個特徵的「維度災難」時，PCA 是最常被採用的線性降維利器。它的目的不是單純地刪除特徵，而是透過數學正交變換，將原本高度相關的高維特徵重新組合，投影到一組全新且彼此正交（互不相關）的低維特徵軸上，這些新軸被稱為**主成分 (Principal Components, PC)**。

PCA 的核心數學準則是：**在投影後的新維度上，儘可能保留原始資料的變異數 (Variance)**。第一主成分承載了最多的資料變異資訊，第二主成分次之，依此類推。透過捨棄後面資訊量極低的主成分，我們可以用極少的新特徵代表原本龐大的資料集，大幅降低後續模型的運算負荷並防止過擬合。

Rank 10: 神經網路與深度學習 (Neural Networks / Deep Learning)

監督 / 無監督皆可 主要用途：影像辨識、自然語言處理 (NLP)、複雜未知模式識別

核心運作原理：

人工神經網路 (ANN) 是受到人類大腦生物神經元網絡啟發而設計的複雜架構。它由輸入層 (Input Layer)、多個隱藏層 (Hidden Layers) 以及輸出層 (Output Layer) 組成。每個層級包含許多節點（神經元），節點間透過「權重 (Weights)」相連。

資料從輸入層進入，經過各層節點的權重加權求和，並通過非線性**激活函數 (Activation Function)**（如 ReLU, Tanh）向後傳遞，最終在輸出層產生預測，此過程稱為**前向傳播 (Forward Propagation)**。

深度學習的強大之處在於透過**反向傳播演算法 (Backpropagation)** 結合梯度下降，從輸出端的錯誤誤差 (Loss) 開始，由後往前計算每個權重對誤差的貢獻度，並自動調整優化數百萬甚至數十億個參數。這使得深度學習具備「自動特徵提取」的能力，徹底顛覆了傳統機器學習需要高度依賴人工進行特徵工程的限制。

四、初學者最佳化學習路徑藍圖

如資訊圖表中所推薦的黃金金字塔路徑，初學者不應盲目直接切入複雜的神經網路，而應依循結構化的邏輯，由淺入深、循序漸進地實踐：

第一階段：建立數值與概率基石 (Rank 1 & 2 & 6)

優先掌握 **Linear Regression** 與 **Logistic Regression**，理解權重、損失函數與梯度下降。接著引入 **KNN**，體會空間幾何距離的概念。

第二階段：跨入樹狀與規則模型 (Rank 3 & 4 & 7)

學習 **Decision Tree** 及其背後的資訊純度邏輯，隨後無縫接軌到功能強大的集成模組 **Random Forest**。期間穿插 **Naive Bayes** 學習條件機率的實務應用。

第三階段：進階高維幾何與無監督範式 (Rank 5 & 8 & 9)

挑戰數學層面較高的 **SVM**，搞懂超平面與核函數。隨後轉入無監督領域，用 **K-Means** 訓練資料分群思維，並用 **PCA** 掌握矩陣分解與降維技術。

第四階段：終極探索感知器與感知網絡 (Rank 10)

在前九大經典機器學習演算法的厚實基礎下，正式邁入 **Neural Networks / Deep Learning**，探索多層感知、卷積與變形金剛 (Transformer) 等當代頂尖架構。

💡 實戰修煉指引 (Tip for Success)：

1. **理解概念 (Understand the concepts)**：優先弄懂各演算法的物理意義與限制，而非死記公式。
2. **實戰真實數據集 (Practice on real datasets)**：利用 Kaggle 或 UCI 平台，動手使用 Scikit-Learn 呼叫模型並調參。
3. **構建專案 (Build projects)**：從端到端的資料清理、模型訓練到最終評估，完成屬於自己的獨立專案。
4. **持續疊代 (Keep iterating!)**：機器學習是一門實驗科學，優化模型與特徵是永無止境的精進旅程。